

# DCS440 最优化理论

## 第二章：对偶理论

杨磊

yanglei39@mail.sysu.edu.cn

计算机学院，2023秋

致谢：本课件由谷曜东、朱嘉懿、郑嘉祺协助准备

## § Lagrange 对偶

### § Lagrange 对偶问题

### § Lagrange 对偶的几种解释

### § 最优性条件

### § 敏感性分析

考虑一般优化问题（可能非凸）

$$\begin{aligned} \min \quad & f_0(x) \\ \text{s.t.} \quad & f_i(x) \leq 0, \quad i = 1, \dots, m, \\ & h_j(x) = 0, \quad j = 1, \dots, p. \end{aligned}$$

对于上面这个一般形式的优化问题，假设：

- 问题的定义域  $\mathcal{D} := \bigcap_{i=0}^m \text{dom } f_i \cap \bigcap_{j=1}^p \text{dom } h_j$  非空；
- 问题的最优解  $x^*$  和 最优值  $p^*$  存在。

不严谨地说，拉格朗日(Lagrange)对偶的基本思想：将原约束优化问题的目标和约束放在同一个函数（即拉格朗日函数）中来研究。

以一般优化问题为例，它的 Lagrange 函数  $L : \mathbb{R}^n \times \mathbb{R}^m \times \mathbb{R}^p \rightarrow \mathbb{R}$  定义为

$$L(x, \lambda, \nu) := f_0(x) + \sum_{i=1}^m \lambda_i f_i(x) + \sum_{j=1}^p \nu_j h_j(x),$$

其中：

- $L(x, \lambda, \nu)$  的**定义域**为  $\text{dom } L = \mathcal{D} \times \mathbb{R}^m \times \mathbb{R}^p$ ;
- $\lambda_i$  称为第  $i$  个**不等式约束**  $f_i(x) \leq 0$  对应的 **Lagrange 乘子**;
- $\nu_j$  称为第  $j$  个**等式约束**  $h_j(x) = 0$  对应的 **Lagrange 乘子**;
- 向量  $\lambda$  和  $\nu$  是分别由  $\lambda_i$  和  $\nu_j$  组成的向量，称作优化问题的**对偶变量 (dual variable)** 或者 **Lagrange 乘子**;
- 此时，将目标变量  $x$  称作**原变量 (primal variable)**。

定义 **Lagrange 对偶函数**（简称**对偶函数**，dual function）如下：

$$\begin{aligned} g(\lambda, \nu) &:= \inf_{x \in \mathcal{D}} L(x, \lambda, \nu) \\ &= \inf_{x \in \mathcal{D}} \left\{ f_0(x) + \sum_{i=1}^m \lambda_i f_i(x) + \sum_{j=1}^p \nu_j h_j(x) \right\}. \end{aligned}$$

性质一：  $g(\lambda, \nu)$  是**关于  $\lambda$  和  $\nu$  的凹函数**！（思考：为什么？）

答：  $g(\lambda, \nu)$  是一族**关于  $(\lambda, \nu)$  的仿射函数的逐点下确界**，因此即使优化问题非凸，其对偶函数  $g(\lambda, \nu)$  也是**凹函数**。

性质二：对  $\forall \lambda \geq 0$  和  $\forall \nu$ ，可以推出  $g(\lambda, \nu) \leq p^*$ （见下一页），即  $g(\lambda, \nu)$  给出了原问题最优值的下界。

启发：可通过计算以下优化问题（称作**对偶问题**）得到原约束优化问题最优值  $p^*$  的**最紧下界**：

$$\sup_{\lambda, \nu} \quad g(\lambda, \nu) \quad \text{s.t.} \quad \lambda \geq 0.$$



# 弱对偶定理

## 定理 1 (弱对偶定理)

对  $\forall \lambda \geq 0$  和  $\forall \nu$ , 有  $g(\lambda, \nu) \leq p^*$ 。

证明: 设  $x^* \in \mathcal{D}$  是原问题的最优解, 则有  $f_i(x^*) \leq 0$ ,  $h_j(x^*) = 0$ 。于是, 对  $\forall \lambda \geq 0$  和  $\forall \nu$ , 有

$$\underbrace{\sum_{i=1}^m \lambda_i f_i(x^*)}_{\leq 0} + \underbrace{\sum_{j=1}^p \nu_j h_j(x^*)}_{=0} \leq 0.$$

因此

$$L(x^*, \lambda, \nu) = f_0(x^*) + \sum_{i=1}^m \lambda_i f_i(x^*) + \sum_{j=1}^p \nu_j h_j(x^*) \leq f_0(x^*) = p^*.$$

进一步, 有

$$g(\lambda, \nu) = \inf_{x \in \mathcal{D}} L(x, \lambda, \nu) \leq L(x^*, \lambda, \nu) \leq f_0(x^*) = p^*.$$



# 例：线性规划

## 线性规划问题（标准型）

$$\begin{aligned} \min_x \quad & c^\top x \\ \text{s.t.} \quad & Ax = b \quad \Rightarrow \quad Ax - b = 0 \\ & x \geq 0 \quad \Rightarrow \quad -x \leq 0 \end{aligned}$$

假设可行域非空。对不等式约束  $-x \leq 0$  和等式约束  $Ax - b = 0$  分别引入 Lagrange 乘子  $\lambda$  和  $\nu$ ，得到 Lagrange 函数：

$$L(x, \lambda, \nu) = c^\top x + \nu^\top (Ax - b) + \lambda^\top (-x) = -b^\top \nu + (A^\top \nu - \lambda + c)^\top x.$$

于是，对偶函数为

$$g(\lambda, \nu) = \inf_x L(x, \lambda, \nu) = -b^\top \nu + \inf_x \{ (A^\top \nu - \lambda + c)^\top x \}$$



# 例：线性规划

容易分析得到

$$\begin{aligned} g(\lambda, \nu) &= \inf_x L(x, \lambda, \nu) = -b^\top \nu + \inf_x \{ (A^\top \nu - \lambda + c)^\top x \} \\ &= \begin{cases} -b^\top \nu, & A^\top \nu - \lambda + c = 0, \\ -\infty, & \text{otherwise.} \end{cases} \end{aligned}$$

于是，由弱对偶定理可知

$$p^* \text{ 的下界是: } \begin{cases} -b^\top \nu, & A^\top \nu - \lambda + c = 0, \lambda \geq 0, \\ -\infty, & \text{otherwise.} \end{cases} \quad (\text{显然, 该下界无意义})$$

相应的对偶问题如下:

$$\max_{\lambda, \nu} \quad -b^\top \nu \quad \text{s.t.} \quad A^\top \nu - \lambda + c = 0, \lambda \geq 0.$$

上述问题进一步等价于

$$\max_{\nu} \quad -b^\top \nu \quad \text{s.t.} \quad A^\top \nu + c \geq 0.$$





# 例：线性约束的最小二乘问题

## 线性约束的最小二乘解问题

$$\begin{array}{ll} \min & x^\top x \\ \text{s.t.} & Ax = b \quad \Rightarrow \quad Ax - b = 0 \end{array}$$

为等式约束  $Ax - b = 0$  引入 Lagrange 乘子  $\nu$ ，得到 Lagrange 函数

$$L(x, \nu) = x^\top x + \nu^\top (Ax - b).$$

因为  $L(x, \nu)$  是关于  $x$  的二次可微凸函数，因此关于  $x$  的最优解可通过一阶最优性条件得到

$$\nabla_x L(x, \nu) = 2x + A^\top \nu = 0 \quad \Rightarrow \quad x_\nu^* = -\frac{1}{2} A^\top \nu.$$

因此，对偶函数为

$$g(\nu) = \inf_x L(x, \nu) = L(x_\nu^*, \nu) = L(-\frac{1}{2} A^\top \nu, \nu) = -\frac{1}{4} \nu^\top A A^\top \nu - b^\top \nu.$$



# 例：线性约束的最小二乘问题

该对偶函数显然是凹函数

$$g(\nu) = -\frac{1}{4} \nu^\top A A^\top \nu - b^\top \nu.$$

进一步，由弱对偶定理可知：

$$\begin{aligned} 1. \quad & \inf_{x \in \mathbb{R}^n} \{x^\top x \mid Ax = b\} \geq -\frac{1}{4} \nu^\top A A^\top \nu - b^\top \nu, \quad \forall \nu \\ 2. \quad & \inf_{x \in \mathbb{R}^n} \{x^\top x \mid Ax = b\} \geq \underbrace{\sup_{\nu} \left\{ -\frac{1}{4} \nu^\top A A^\top \nu - b^\top \nu \right\}}_{\text{对偶问题}} \end{aligned}$$

关于第 2 点，我们将在以后说明，当  $Ax = b$  解集非空时不等式会取等号（此时，强对偶性成立）。



# 例：双向划分问题

## 双向划分问题

$$\begin{aligned} \min_x \quad & x^\top W x \\ \text{s.t.} \quad & x_i^2 = 1, \quad i = 1, 2, \dots, n, \end{aligned}$$

其中  $W \in S^n$ ,  $x \in \mathbb{R}^n$ , 且其分量  $x_i$  取值为 1 或  $-1$ 。

为等式约束  $x_i^2 - 1 = 0$  引入拉格朗日乘子  $\nu_i$ , 得到 **Lagrange** 函数:

$$L(x, \nu) = x^\top W x + \sum_{i=1}^n \nu_i (x_i^2 - 1) = x^\top (W + \text{diag}(\nu)) x - \mathbf{1}^\top \nu,$$

其中  $\mathbf{1} := (1, 1, \dots, 1)^\top$ .

进一步, 对  $x$  求极小, 得到**对偶函数**:

$$g(\nu) = \inf_x \{x^\top (W + \text{diag}(\nu)) x\} - \mathbf{1}^\top \nu = \begin{cases} -\mathbf{1}^\top \nu, & W + \text{diag}(\nu) \succeq 0, \\ -\infty, & \text{otherwise.} \end{cases}$$

## 仿射约束的优化问题

$$\begin{aligned} \min \quad & f_0(x) \\ \text{s.t.} \quad & Ax \leq b \\ & Cx = d \end{aligned}$$

回顾凸函数  $f: \mathbb{R}^n \rightarrow \mathbb{R}$  的**共轭函数**:  $f^*(y) = \sup_{x \in \text{dom } f} \{y^\top x - f(x)\}$

下面, 利用函数  $f_0$  的**共轭函数**  $f_0^*$  表述问题的**对偶函数**:

$$\begin{aligned} g(\lambda, \nu) &= \inf_{x \in \text{dom } f_0} L(x, \lambda, \nu) = \inf_{x \in \text{dom } f_0} \{f_0(x) + \lambda^\top (Ax - b) + \nu^\top (Cx - d)\} \\ &= \inf_{x \in \text{dom } f_0} \left\{ f_0(x) + (A^\top \lambda + C^\top \nu)^\top x \right\} - \lambda^\top b - \nu^\top d \\ &= -f_0^* (-A^\top \lambda - C^\top \nu) - \lambda^\top b - \nu^\top d \end{aligned}$$



# 例：最大熵问题

## 最大熵问题

$$\begin{aligned} \min \quad & f_0(x) = \sum_{i=1}^n x_i \log x_i \\ \text{s.t.} \quad & Ax \leq b \\ & \mathbf{1}^\top x = 1 \end{aligned}$$

对于  $f_0$ ，其定义域为  $\text{dom } f_0 = \mathbb{R}_+^n$ ；

$f_0$  的共轭函数为  $f_0^*(y) = \sum_{i=1}^n e^{y_i - 1}$ ，其定义域为  $\text{dom } f_0^* = \mathbb{R}^n$ 。

于是，最大熵问题的对偶函数为

$$\begin{aligned} g(\lambda, \nu) &= -f_0^*(-A^\top \lambda - \nu \mathbf{1}) - \lambda^\top b - \nu \\ &= -\lambda^\top b - \nu - \sum_{i=1}^n e^{-a_i^\top \lambda - \nu - 1} = -\lambda^\top b - \nu - e^{-\nu - 1} \sum_{i=1}^n e^{-a_i^\top \lambda}, \end{aligned}$$

其中  $a_i$  表示矩阵  $A$  的第  $i$  列向量。

§ Lagrange 对偶

§ **Lagrange 对偶问题**

§ Lagrange 对偶的几种解释

§ 最优性条件

§ 敏感性分析



# Lagrange 对偶问题

回顾弱对偶定理：对于 Lagrange 对偶函数  $g(\lambda, \nu)$ ，对任意  $\forall \lambda \geq 0$  和  $\forall \nu$ ， $g(\lambda, \nu)$  给出了原优化问题最优值  $p^*$  的一个下界。

显然，该下界和乘子  $\lambda$  和  $\nu$  的选取相关。而当我们极大化对偶函数  $g(\lambda, \nu)$ ，试图计算  $p^*$  的最紧下界时，就引出了原问题的 **Lagrange 对偶问题**：

## Lagrange 对偶问题

$$\begin{array}{ll} \min_x & f_0(x) \\ \text{s.t.} & f_i(x) \leq 0, \\ & h_j(x) = 0. \end{array} \quad (\text{Primal}) \qquad \begin{array}{ll} \sup / \max & g(\lambda, \nu) \\ \text{s.t.} & \lambda \geq 0 \end{array} \quad (\text{Dual})$$

- 左侧即为原问题(Primal)，右侧即为 Lagrange 对偶问题(Dual)
- 原问题(Primal)的最优值为  $p^* \geq$  对偶问题(Dual)的最优值为  $d^*$
- 对偶问题(Dual)的最优解  $(\lambda^*, \nu^*)$  称为对偶最优解或最优 Lagrange 乘子
- 无论原问题(Primal)是否为凸，对偶问题(Dual)总是一个凹优化问题
- 为方便，后面出现的对偶问题无论解是否存在，我们都用符号  $\max$



# 例：线性规划的对偶问题

## 考虑线性规划问题

$$\begin{array}{ll} \min_x & c^\top x \\ \text{s.t.} & Ax = b \\ & x \geq 0 \end{array} \quad (\text{Primal})$$

已推导其 Lagrange 对偶函数为

$$g(\lambda, \nu) = \begin{cases} -b^\top \nu, & A^\top \nu - \lambda + c = 0, \\ -\infty, & \text{otherwise.} \end{cases}$$

进一步，写出 Lagrange 对偶问题：

$$\begin{array}{ll} \max_{\lambda, \nu} & g(\lambda, \nu) = -b^\top \nu \\ \text{s.t.} & A^\top \nu - \lambda + c = 0 \\ & \lambda \geq 0 \end{array} \quad (\text{Dual})$$





## 例：线性规划的对偶问题（续）

解析：已推导其 Lagrange 对偶函数为

$$g(\lambda, \nu) = \begin{cases} -b^\top \nu, & A^\top \nu - \lambda + c = 0, \\ -\infty, & \text{otherwise.} \end{cases}$$

- 当  $g(\lambda, \nu) = -\infty$  时，极大化它是没有意义的；
- 因此对偶问题事实上具有隐含的约束条件  $A^\top \nu - \lambda + c = 0$ ;

$$\begin{aligned} \max_{\lambda, \nu} \quad & g(\lambda, \nu) = -b^\top \nu \\ \text{s.t.} \quad & A^\top \nu - \lambda + c = 0 \\ & \lambda \geq 0 \end{aligned} \quad (\text{Dual})$$

- 进一步地，乘子  $\lambda$  可以被隐去：

$$\begin{aligned} \max_{\nu} \quad & g(\lambda, \nu) = -b^\top \nu \\ \text{s.t.} \quad & A^\top \nu + c \geq 0 \quad (A^\top \nu + c = \lambda \geq 0) \end{aligned} \quad (\text{Dual})$$



# 例：线性约束的最小二乘

## 回顾线性约束的最小二乘问题

$$\begin{array}{ll} \min & x^\top x \\ \text{s.t.} & Ax = b \end{array} \quad (\text{Primal})$$

已推导其 Lagrange 对偶函数为

$$g(\nu) = L(-\frac{1}{2}A^\top \nu, \nu) = -\frac{1}{4}\nu^\top AA^\top \nu - b^\top \nu.$$

进一步，写出 Lagrange 对偶问题：

$$\begin{aligned} \max_{\nu} \quad & g(\nu) = -\frac{1}{4}\nu^\top AA^\top \nu - b^\top \nu \\ \iff \min_{\nu} \quad & \frac{1}{4}\nu^\top AA^\top \nu + b^\top \nu \end{aligned} \quad (\text{Dual})$$

设原问题(Primal)的最优值为  $p^* = f_0(x^*)$ , 对偶问题(Dual)的最优值为  $d^* = g(\lambda^*, \nu^*)$ 。<sup>1</sup> 于是,

- 不等式  $d^* \leq p^*$  总是成立的, 称为弱对偶性 (weak duality)
- 等式  $d^* = p^*$  不必然成立! 当等式成立时, 称为强对偶性 (strong duality)
- 差值  $p^* - d^*$  称为对偶间隙 (duality gap), 根据弱对偶性可知对偶间隙总是非负的

**思考:** 什么情况下强对偶性成立, 即对偶间隙为 0?

---

<sup>1</sup>注意: 这里的  $p^*$  可以为  $-\infty$ , 此时由弱对偶性可知  $d^* = -\infty$ , 因此强对偶性成立。为方便, 我们后面都假设  $p^*$  为有限数。

显然，**强对偶性**是很好的性质。如果成立，则可以通过求解**对偶问题**来求解**原问题的最优值**。遗憾的是，一般情况下强对偶性并不成立。

但是，对于**凸优化问题**，在一定（不是特别强）的条件下，**强对偶性**是成立的，这也说明了凸优化问题的优势。

## 考虑一般形式的凸优化问题

$$\begin{aligned} \min \quad & f_0(x) \\ \text{s.t.} \quad & f_i(x) \leq 0, \quad i = 1, \dots, m \quad (f_0, \dots, f_m \text{ 凸}) \\ & Ax = b. \end{aligned}$$

针对上述问题，文献中已经给出了很多**强对偶性**成立的条件，其中一个相对简单且被广泛应用的条件是 **Slater's condition**。

介绍 Slater's condition 之前, 首先介绍集  $\mathcal{D}$  的相对内点集合  $\text{relint } \mathcal{D}$ 。

给定集合  $\mathcal{D}$ , 回顾其仿射包的定义如下:

$$\text{aff } \mathcal{D} := \left\{ x \mid x = \sum_{i=1}^k \theta_i x_i, \forall x_1, x_2, \dots, x_k \in \mathcal{D}, \sum_{i=1}^k \theta_i = 1 \right\}.$$

回顾其内点集的定义如下: ( $B(x, r)$  为以  $x$  为中心, 半径为  $r$  的范数球)

$$\text{int } \mathcal{D} = \left\{ x \in \mathcal{D} \mid \exists r > 0, \text{ s.t. } B(x, r) \subseteq \mathcal{D} \right\}.$$

## 定义 1 (相对内点 (relative interior))

集合  $\mathcal{D}$  的相对内点集定义为

$$\text{relint } \mathcal{D} := \left\{ x \in \mathcal{D} \mid \exists r > 0, \text{ s.t. } B(x, r) \cap \text{aff } \mathcal{D} \subseteq \mathcal{D} \right\}.$$

解析: 不严谨地说, 相对内点可以看作内点的推广!

- 当  $\text{aff } \mathcal{D} = \mathbb{R}^n$  时, 相对内点等价于内点;
- 当  $\mathcal{D}$  本身的“维度”较低 (例如,  $\mathcal{D}$  为  $\mathbb{R}^n$  中的某个超平面) 时,  $\mathcal{D}$  中不存在内点, 因此需引入“相对”的概念, 以适应更复杂的情况。

## Slater's condition

若存在一点  $x \in \text{relint } \mathcal{D}$ , 使得凸优化问题的约束满足:

$$f_i(x) < 0, \quad i = 1, \dots, m, \quad Ax = b.$$

则称: 此问题满足 **Slater's condition**, 进一步, 此问题的**强对偶性**成立。

- 满足上述条件的点也称为**严格可行点**, 因为**不等式约束严格成立**
- Slater's condition 要求  $\text{relint } \mathcal{D}$  中存在使得不等式约束严格成立的点

当不等式约束函数中**有部分是仿射的**时, Slater's condition 可**弱化**如下:

## 弱化的 Slater's condition

不失一般性, 设前  $k$  个不等式约束函数  $f_1, \dots, f_k$  是仿射的, 若存在一点  $x \in \text{relint } \mathcal{D}$ , 使得凸优化问题的约束满足:

$$\underline{f_i(x) \leq 0}, \quad i = 1, \dots, k, \quad f_i(x) < 0, \quad i = k + 1, \dots, m, \quad Ax = b.$$

则此问题的**强对偶性**成立。由此可看出, **仿射不等式不需要严格成立**。



# 例：线性约束的最小二乘问题

## 线性约束的最小二乘问题

$$\begin{array}{ll} \min & x^\top x \\ \text{s.t.} & Ax = b \end{array} \quad (\text{Primal})$$

已推导其 Lagrange 对偶问题为：

$$\begin{aligned} \max_{\nu} \quad & g(\nu) = -\frac{1}{4}\nu^\top AA^\top \nu - b^\top \nu \\ \iff \min_{\nu} \quad & \frac{1}{4}\nu^\top AA^\top \nu + b^\top \nu \end{aligned} \quad (\text{Dual})$$

于是，对于该问题，只要原问题可行，即  $\exists x, \text{ s.t. } Ax = b$ ，则必有强对偶性成立。



# 例：线性规划

考虑线性规划问题（假设目标函数值在可行域上有下界）

$$\begin{aligned} \min_{x} \quad & c^\top x \\ \text{s.t.} \quad & Ax = b \\ & x \geq 0 \end{aligned} \quad (\text{Primal})$$

已推导其 Lagrange 对偶问题：

$$\max_{\lambda, \nu} \quad -b^\top \nu \quad \text{s.t.} \quad A^\top \nu - \lambda + c = 0, \quad \lambda \geq 0. \quad (\text{Dual})$$

根据弱化的 Slater's condition，对于线性规划问题：

- 只要原问题(Primal)可行，则**强对偶性**成立；
- 由于对偶也是线性规划，因此如果对偶(Dual)可行，则**强对偶性**成立；
- 只有一种情况下**强对偶性不成立**：(Primal)和(Dual)均不可行。

★ **特别强调** ★：针对线性规划问题，这里的**强对偶性**（对偶间隙为零，包含  $p^* = d^* = -\infty$  的情况）与其他教材中的**强对偶定理**有所不同！



## 二次约束二次规划问题(QCQP)

$$\begin{aligned} \min_x \quad & \frac{1}{2}x^\top P_0 x + q_0^\top x + r_0, \quad P_0 \in S_{++}^n, \\ \text{s.t.} \quad & \frac{1}{2}x^\top P_i x + q_i^\top x + r_i \leq 0, \quad P_i \in S_+^n, \quad i = 1, 2, \dots, m, \end{aligned} \quad (\text{Primal})$$

引入 Lagrange 乘子向量  $\lambda$ , 写出其 Lagrange 函数为

$$\begin{aligned} L(x, \lambda) &= \frac{1}{2}x^\top P_0 x + q_0^\top x + r_0 + \sum_{i=1}^m \lambda_i \left( \frac{1}{2}x^\top P_i x + q_i^\top x + r_i \right) \\ &= \frac{1}{2}x^\top \underbrace{\left( P_0 + \sum_{i=1}^m \lambda_i P_i \right)}_{\triangleq P(\lambda)} x + \underbrace{\left( q_0 + \sum_{i=1}^m \lambda_i q_i \right)^\top}_{\triangleq q(\lambda)} x + \underbrace{\left( r_0 + \sum_{i=1}^m \lambda_i r_i \right)}_{\triangleq r(\lambda)} \\ &= \frac{1}{2}x^\top P(\lambda) x + q(\lambda)^\top x + r(\lambda) \end{aligned}$$

不难分析, 其 Lagrange 对偶函数只在  $P(\lambda) \succeq 0$  时才可能有意义, 但具体形式不易推得 (不严谨地说, 因为解的形式不易由对偶变量显示表达)。

不过注意到, 为得到原问题最优值的下界, 对偶变量  $\lambda$  最终要求为非负, 因此我们可以只考虑  $\lambda \geq 0$  情况下的对偶函数, 此时有  $P(\lambda) \succ 0$ 。于是, 有

$$g(\lambda) = \inf_x L(x, \lambda) = \begin{cases} -(1/2) q(\lambda)^\top P(\lambda)^{-1} q(\lambda) + r(\lambda), & \lambda \geq 0, \\ \text{不易推得}, & \text{otherwise.} \end{cases}$$

进一步, 可写出对偶问题

$$\max_{\lambda \geq 0} \quad -(1/2) q(\lambda)^\top P(\lambda)^{-1} q(\lambda) + r(\lambda). \quad (\text{Dual})$$

最后, 由 Slater's condition, 若  $\exists x$  使得所有二次不等式约束严格成立, 即

$$(1/2) x^\top P_i x + q_i^\top x + r_i < 0, \quad i = 1, 2, \dots, m,$$

则 QCQP 的强对偶性成立。



# 例：最大熵问题

## 最大熵问题

$$\begin{aligned} \min \quad & f_0(x) = \sum_{i=1}^n x_i \log x_i \quad (\text{dom } f_0 = \mathbb{R}_{++}^n) \\ \text{s.t.} \quad & Ax \leq b \\ & \mathbf{1}^\top x = 1 \end{aligned}$$

根据之前推导的 Lagrange 对偶函数，直接写出对偶问题：

$$\begin{aligned} \max \quad & -b^\top \lambda - \nu - e^{-\nu-1} \sum_{i=1}^n e^{-a_i^\top \lambda} \\ \text{s.t.} \quad & \lambda \geq 0 \end{aligned}$$

于是，由弱化的 Slater's condition，若  $\exists x > 0$  使得  $Ax \leq b$ ,  $\mathbf{1}^\top x = 1$ ，则**强对偶性**成立。

Slater's condition 是凸问题**强对偶性**成立的充分条件，但不是必要条件！

例:

$$\begin{aligned} \min \quad & x \\ \text{s.t.} \quad & x \leq 0, \quad -x \leq 0. \end{aligned} \quad (\text{Primal})$$

(i). 由于(Primal)的可行点只有  $x = 0$ ，故可行域不存在相对内部，因此原问题显然不满足 Slater's condition。易知，(Primal)的最优值  $p^* = 0$ 。

(ii). 进一步，考察它的 Lagrange 对偶函数：

$$\begin{aligned} \Rightarrow \quad L(x, \lambda_1, \lambda_2) &= x + \lambda_1 x - \lambda_2 x \\ \Rightarrow \quad g(\lambda_1, \lambda_2) &= \inf_x L(x, \lambda_1, \lambda_2) = \begin{cases} 0, & 1 + \lambda_1 - \lambda_2 = 0, \\ -\infty, & \text{otherwise.} \end{cases} \end{aligned}$$

得到对偶问题:

$$\begin{aligned} \max \quad & 0 \\ \text{s.t.} \quad & 1 + \lambda_1 - \lambda_2 = 0, \quad \lambda_1, \lambda_2 \geq 0. \end{aligned} \quad (\text{Dual})$$

显然，(Dual)的最优值  $d^* = p^* = 0$ ，此时**强对偶性**成立。



扩展知识：非凸问题仍然可能有强对偶性。

例：置信域问题 (trust region problem).<sup>1</sup> 在单位球内极小化一个二次函数

$$\begin{aligned} \min \quad & x^\top Ax + 2b^\top x \quad (A \in S^n, b \in \mathbb{R}^n) \\ \text{s.t.} \quad & x^\top x \leq 1. \end{aligned}$$

若  $A \not\succeq 0$ , 则目标函数  $f_0 = x^\top Ax$  是非凸的。但是，该问题对偶间隙为 0。

---

<sup>1</sup> 参见 **Section 5**, Ronald J. Stern and Henry Wolkowicz. Indefinite trust region subproblems and nonsymmetric eigenvalue perturbations. *SIAM Journal on Optimization*, 5(2): 286–313, 1995.

§ Lagrange 对偶

§ Lagrange 对偶问题

§ Lagrange 对偶的几种解释

§ 最优性条件

§ 敏感性分析

我们从函数值集合的角度去理解 Lagrange 对偶。

考虑仅有一个不等式约束的优化问题（假设目标函数值在可行域上有下界）

$$\begin{aligned} \inf_x \quad & f_0(x) \\ \text{s.t.} \quad & f_1(x) \leq 0. \end{aligned}$$

记问题的定义域为  $\mathcal{D} := \text{dom } f_0 \cap \text{dom } f_1$ .


首先，定义如下符号：

- 集合  $\mathcal{G} := \{ (f_1(x), f_0(x)) \mid x \in \mathcal{D} \}$
- 最优值  $p^* := \inf_t \{ t \mid (u, t) \in \mathcal{G}, u \leq 0 \} \iff \inf_{x \in \mathcal{D}} \{ f_0 \mid f_1 \leq 0 \}$
- 对偶函数

$$g(\lambda) := \inf_{t,u} \{ t + \lambda u \mid (u, t) \in \mathcal{G} \} \iff \inf_{x \in \mathcal{D}} \underbrace{\{ f_0(x) + \lambda f_1(x) \}}_{L(x, \lambda)}$$

然后, 作出变量  $(u, t) \in \mathcal{G}$  的图像:


- 集合  $\mathcal{G}$  对应图中的阴影部分;
- 最优值  $p^*$  对应应在集合  $\mathcal{G}$  中, 当  $u \leq 0$  时,  $t$  能取到的最小值;
- 对偶函数  $g(\lambda)$  对应一条以  $u$  为自变量,  $t$  为因变量, 斜率为  $-\lambda$ , 必过集合  $\mathcal{G}$  中一点, 且在  $t$  方向上的“截距”最小的直线。





下图展示了  $\lambda$  分别取值  $\lambda_1$ ,  $\lambda_2$  和  $\lambda^*$  时, 对偶函数  $g(\lambda)$  对应的直线:

- 对任意  $\lambda$ ,  $g(\lambda)$  对应的直线都与集合  $\mathcal{G}$  相切 (保证至少经过集合  $\mathcal{G}$  中一点), 且使得  $t$  方向截距最小;
- 对偶问题  $\sup \{g(\lambda) \mid \lambda \geq 0\}$ : 在斜率  $-\lambda \leq 0$  的情况下找到上述“最小截距”中的“最大值, 即原问题最优值的最大下界”。易分析, 在图中, 对偶最优解为  $\lambda^*$ , 则  $g(\lambda^*)$  在  $t$  轴上的截距为  $d^*$ ;
- 在本例中, 易观察到  $d^* < p^*$ , 即弱对偶性成立, 但强对偶性不成立。



Lagrange 对偶也有着有趣的经济学解释。考虑这样一个场景：给定若干原材料，制定生产方案，卖产品，希望获得最大利润。

数学上，可以考虑如下含有多个不等式约束的优化问题：

$$\begin{aligned} \min \quad & -f_0(x) \\ \text{s.t.} \quad & x_i \leq u_i, \quad i = 1, \dots, m, \end{aligned}$$

其中

- $x$  表示产量；
- $f_0(x)$  表示利润；（注：最小化负利润  $\Leftrightarrow$  最大化利润）
- $x_i \leq u_i$  表示对第  $i$  种原材料用量的限制。

记求解该问题得到的（只卖产品的）最优生产方案为  $x^*$ ，最优值为  $p^*$ 。

现假设原材料能够自由买卖, 设第  $i$  种原材料的价格为  $\lambda_i \geq 0$ 。此时, 我们可考虑更灵活的生产方案, 既可以卖产品, 也可以买卖原材料。

于是, 对于一个生产方案  $x$ :

- 若  $x_i \leq u_i$ , 表示第  $i$  种原材料库存有剩余, 可以出售, 以便增加利润  $\lambda_i(u_i - x_i)$ 。此时, 总共的负利润可以表示为

$$-(f_0(x) + \sum_{i=1}^m \lambda_i(u_i - x_i))$$

- 若  $x_i > u_i$ , 表示第  $i$  种原材料要额外购入, 以满足生产需求, 但会产生额外原材料花销  $\lambda_i(x_i - u_i)$ 。此时, 总共的负利润可以表示为

$$-(f_0(x) - \sum_{i=1}^m \lambda_i(x_i - u_i))$$

综上, 在原材料能够自由买卖市场下, 总共的负利润为 (Lagrange 函数)

$$L(x, \lambda) := -f_0(x) + \sum_{i=1}^m \lambda_i(x_i - u_i)$$

于是，**对偶函数**表示给定原材料价格时，**最优生产方案的最小负利润**：

$$g(\lambda) \triangleq \inf_{x \in \mathcal{D}} \left\{ -f_0(x) + \sum_{i=1}^m \lambda_i (x_i - u_i) \right\}.$$

**注意：**无论原材料价格  $\lambda$  如何变化，由于可以自由买卖，生产方案更多样化，因此获利只可能更多，负利润只可能更小，即  $g(\lambda) \leq p^*$ 。

进一步，若**强对偶性成立**，即  $d^* = g(\lambda^*) = p^*$ ，则表明：

当原材料定价为  $\lambda^*$ ，生产方案设定为  $x^*$  时，通过**自由买卖**购入额外的原材料扩大生产，或卖出原材料获得利润，**都不能获得更高的收益**，此时资源已调配至最优。

在经济学领域， $\lambda^*$  也被称为影子价格。

Lagrange 对偶也能从多目标规划的角度来理解:

考虑带有多个不等式约束的优化问题

$$\begin{aligned} \min_x \quad & f_0(x) \\ \text{s.t.} \quad & f_i(x) \leq 0, \quad i = 1, \dots, m. \end{aligned}$$

写出 Lagrange 对偶函数:  $L(x, \lambda) = f_0(x) + \sum_{i=1}^m \lambda_i f_i(x)$ .

当  $\lambda \geq 0$  时,  $\inf_x L(x, \lambda) = \inf_x \left\{ f_0(x) + \sum_{i=1}^m \lambda_i f_i(x) \right\}$  对应于求解多目标优化问题

$$\min_x [f_0(x), f_1(x), \dots, f_m(x)]$$

的一个帕累托最优解 (对应权重  $\lambda$ )。

Lagrange 对偶也能从鞍点的角度来理解。首先，我们引入如下不等式。

## 命题 1 (max-min 不等式)

对于任意函数  $f(w, z) : S_w \times S_z \rightarrow \mathbb{R}$ ，以下 max-min 不等式必成立：

$$\sup_{z \in S_z} \inf_{w \in S_w} f(w, z) \leq \inf_{w \in S_w} \sup_{z \in S_z} f(w, z).$$

思考：max-min 不等式中的等式何时成立？

## 定义 2 (鞍点 (saddle point))

对于函数  $f(w, z) : S_w \times S_z \rightarrow \mathbb{R}$ ，若存在  $\exists (\tilde{w}, \tilde{z}) \in S_w \times S_z$  使得

$$f(\tilde{w}, z) \leq f(\tilde{w}, \tilde{z}) \leq f(w, \tilde{z}), \quad \forall w \in S_w, \forall z \in S_z,$$

则称  $(\tilde{w}, \tilde{z})$  为函数  $f(w, z)$  的鞍点 (saddle point)。

由鞍点的定义, 不难看出, 若  $(\tilde{w}, \tilde{z})$  是一个鞍点, 则

- $\tilde{w}$  在  $S_w$  上极小化  $f(w, \tilde{z})$ , 即  $f(\tilde{w}, \tilde{z}) = \inf_{w \in S_w} f(w, \tilde{z})$
- $\tilde{z}$  在  $S_z$  上极大化  $f(\tilde{w}, z)$ , 即  $f(\tilde{w}, \tilde{z}) = \sup_{z \in S_z} f(\tilde{w}, z)$




Fig. 鞍点示意图

## 命题 2

若  $(\tilde{w}, \tilde{z})$  是  $f(w, z)$  的一个鞍点, 则 max-min 不等式在该鞍点处等式成立, 且等于  $f(\tilde{w}, \tilde{z})$ 。

证明: 因为  $(\tilde{w}, \tilde{z})$  是  $f(w, z)$  的一个鞍点, 有

$$f(\tilde{w}, z) \leq f(\tilde{w}, \tilde{z}) \leq f(w, \tilde{z}), \quad \forall w \in S_w, \forall z \in S_z.$$

于是,

$$1. \sup_{z \in S_z} \inf_{w \in S_w} f(w, z) \geq \inf_{w \in S_w} f(w, \tilde{z}) \geq f(\tilde{w}, \tilde{z})$$

$$2. \inf_{w \in S_w} \sup_{z \in S_z} f(w, z) \leq \sup_{z \in S_z} f(\tilde{w}, z) \leq f(\tilde{w}, \tilde{z})$$

$$\text{综合 1 和 2, 有 } \sup_{z \in S_z} \inf_{w \in S_w} f(w, z) \geq \inf_{w \in S_w} \sup_{z \in S_z} f(w, z).$$

另一方面, 由 max-min 不等式, 可知

$$\sup_{z \in S_z} \inf_{w \in S_w} f(w, z) \leq \inf_{w \in S_w} \sup_{z \in S_z} f(w, z).$$

综上, 可得  $\sup_{z \in S_z} \inf_{w \in S_w} f(w, z) = \inf_{w \in S_w} \sup_{z \in S_z} f(w, z) = f(\tilde{w}, \tilde{z})$ , 证毕。



考虑带有多个不等式约束的优化问题 (假设目标函数值在可行域上有下界)

$$\begin{aligned} \min_x \quad & f_0(x) \\ \text{s.t.} \quad & f_i(x) \leq 0 \quad i = 1, \dots, m \end{aligned} \quad (\text{Primal})$$

写出其 Lagrange 函数。然后, 关于  $\lambda$  极大化  $L(x, \lambda)$ , 可得:

$$\begin{aligned} \sup_{\lambda \geq 0} L(x, \lambda) &= \sup_{\lambda \geq 0} \left\{ f_0(x) + \sum_{i=1}^m \lambda_i f_i(x) \right\} \\ &= \begin{cases} f_0(x), & f_i(x) \leq 0, \quad i = 1, \dots, m, \\ +\infty, & \text{otherwise.} \end{cases} \end{aligned} \quad (\star)$$

于是, (Primal)的最优值可表述为:

$$p^* = \inf_{x \in \mathcal{D}} \{ f_0(x) \mid f_i(x) \leq 0, i = 1, \dots, m \} \stackrel{(\star)}{=} \inf_{x \in \mathcal{D}} \sup_{\lambda \geq 0} L(x, \lambda).$$

回忆对偶问题(Dual)及对偶最优值:

$$d^* = \sup_{\lambda \geq 0} \inf_{x \in \mathcal{D}} L(x, \lambda).$$

于是, 根据 max-min 不等式, 有

$$d^* = \sup_{\lambda \geq 0} \inf_{x \in \mathcal{D}} L(x, \lambda) \leq \inf_{x \in \mathcal{D}} \sup_{\lambda \geq 0} L(x, \lambda) = p^*.$$

重要结论:

1. 由 max-min 不等式直接可得  $d^* \leq p^*$  (弱对偶性);
2. 当  $L(x, \lambda)$  有鞍点时, 强对偶性成立, 且鞍点是原对偶最优解。

## 命题 3

$(\tilde{x}, \tilde{\lambda})$  是 Lagrange 函数  $L(x, \lambda)$  的鞍点  $\iff$  强对偶性成立  
且  $(\tilde{x}, \tilde{\lambda})$  为原对偶最优解

证明：先证“ $\Rightarrow$ ”。

若  $(\tilde{x}, \tilde{\lambda})$  为  $L(x, \lambda)$  的鞍点，则强对偶性成立。（命题2的结论）

根据上述结论和鞍点性质，有

$$(a) \quad L(\tilde{x}, \lambda) \leq L(\tilde{x}, \tilde{\lambda}) \leq L(x, \tilde{\lambda}), \quad \forall \lambda \geq 0, \forall x \in \mathcal{D},$$

$$(b) \quad \sup_{\lambda \geq 0} \inf_{x \in \mathcal{D}} L(x, \lambda) = L(\tilde{x}, \tilde{\lambda}) = \inf_{x \in \mathcal{D}} \sup_{\lambda \geq 0} L(x, \lambda).$$

于是, 有

$$g(\tilde{\lambda}) = \inf_{x \in \mathcal{D}} L(x, \tilde{\lambda}) \stackrel{(a)}{=} L(\tilde{x}, \tilde{\lambda}) \stackrel{(b)}{=} \sup_{\lambda \geq 0} \inf_{x \in \mathcal{D}} L(x, \lambda) = \sup_{\lambda \geq 0} g(\lambda),$$

表明  $\tilde{\lambda}$  是对偶问题的最优解。

另一方面, 由

$$f_0(\tilde{x}) \leq \sup_{\lambda \geq 0} \underbrace{\left\{ f_0(\tilde{x}) + \sum_{i=1}^m \lambda_i f_i(\tilde{x}) \right\}}_{L(\tilde{x}, \lambda)} \stackrel{(a)}{=} L(\tilde{x}, \tilde{\lambda})$$

可知  $\sup_{\lambda \geq 0} L(\tilde{x}, \lambda)$  有意义, 因此  $\tilde{x}$  是原问题的可行解, 即  $f_i(\tilde{x}) \leq 0$ ,  $i = 1, \dots, m$ 。进一步, 由

$$f_0(\tilde{x}) \leq L(\tilde{x}, \tilde{\lambda}) \stackrel{(b)}{=} \inf_{x \in \mathcal{D}} \sup_{\lambda \geq 0} L(x, \lambda) \stackrel{(\star)}{=} \inf_{x \in \mathcal{D}} \{ f_0(x) \mid f_i(x) \leq 0, \ i = 1, \dots, m \},$$

可知  $\tilde{x}$  是原问题的最优解。综上, “ $\Rightarrow$ ” 得证。

下面证明: “ $\Leftarrow$ ”

1. 若已知  $(\tilde{x}, \tilde{\lambda})$  为原对偶最优解, 则原对偶必可行, 即

$$f_i(\tilde{x}) \leq 0, \quad i = 1, \dots, m, \quad \tilde{\lambda} \geq 0.$$

2. 又因为强对偶性成立, 因此

$$f_0(\tilde{x}) = g(\tilde{\lambda}) = \underbrace{\inf_{x \in \mathcal{D}} \left\{ f_0(x) + \sum_{i=1}^m \tilde{\lambda}_i f_i(x) \right\}}_{\text{Lagrange 对偶函数}} \leq f_0(\tilde{x}) + \underbrace{\sum_{i=1}^m \tilde{\lambda}_i f_i(\tilde{x})}_{\leq 0} \leq f_0(\tilde{x}),$$

故上式中的等号均成立。

由上式等号都成立, 有

$$f_0(\tilde{x}) + \sum_{i=1}^m \tilde{\lambda}_i f_i(\tilde{x}) = \inf_{x \in \mathcal{D}} \left\{ f_0(x) + \sum_{i=1}^m \tilde{\lambda}_i f_i(x) \right\} \Leftrightarrow L(\tilde{x}, \tilde{\lambda}) = \inf_{x \in \mathcal{D}} L(x, \tilde{\lambda}),$$

即  $L(\tilde{x}, \tilde{\lambda}) \leq L(x, \tilde{\lambda}), \forall x \in \mathcal{D}$ 。

另一方面, 有

$$\begin{aligned} f_0(\tilde{x}) + \sum_{i=1}^m \tilde{\lambda}_i f_i(\tilde{x}) &= f_0(\tilde{x}) = \sup_{\lambda \geq 0} \left\{ f_0(\tilde{x}) + \sum_{i=1}^m \lambda_i f_i(\tilde{x}) \right\} \\ \Leftrightarrow L(\tilde{x}, \tilde{\lambda}) &= \sup_{\lambda \geq 0} L(\tilde{x}, \lambda), \end{aligned}$$

即  $L(\tilde{x}, \tilde{\lambda}) \geq L(\tilde{x}, \lambda), \forall \lambda \geq 0$ 。

综上所述,  $(\tilde{x}, \tilde{\lambda})$  是 Lagrange 函数  $L(x, \lambda)$  的一个鞍点, 证毕。

§ Lagrange 对偶

§ Lagrange 对偶问题

§ Lagrange 对偶的几种解释

§ 最优性条件

§ 敏感性分析



# 最优性条件

最优性条件：研究最优解所要满足的条件。

考虑一般优化问题（可能非凸）

$$\begin{aligned} \min \quad & f_0(x) \\ \text{s.t.} \quad & f_i(x) \leq 0, \quad i = 1, \dots, m, \\ & h_j(x) = 0, \quad j = 1, \dots, p. \end{aligned} \quad (\text{Primal})$$

假设：（考虑简单情形）

- 问题的定义域为  $\mathbb{R}^n$ ，即  $(\bigcap_{i=0}^m \text{dom } f_i) \cap (\bigcap_{j=1}^p \text{dom } h_j) = \mathbb{R}^n$ ；
- 函数  $f_i, i = 0, 1, \dots, m$  和  $h_j, j = 1, 2, \dots, p$  均可微；
- 问题的最优解  $x^*$  和最优值  $p^*$  存在，且强对偶成立。

写出其对偶函数  $g(\lambda, \nu) = \inf_x \left\{ f_0(x) + \sum_{i=1}^m \lambda_i f_i(x) + \sum_{j=1}^p \nu_j h_j(x) \right\}$   
和对偶问题

$$\max_{\lambda, \nu} \quad g(\lambda, \nu), \quad \text{s.t.} \quad \lambda \geq 0. \quad (\text{Dual})$$



假设对偶问题的解也存在，记为  $(\lambda^*, \nu^*)$ 。于是，有

$$\begin{aligned} \underbrace{f_0(x^*) = g(\lambda^*, \nu^*)}_{\text{根据强对偶假设}} &= \inf_x \left\{ f_0(x) + \sum_{i=1}^m \lambda_i^* f_i(x) + \sum_{j=1}^p \nu_j^* h_j(x) \right\} \\ &\leq f_0(x^*) + \sum_{i=1}^m \underbrace{\lambda_i^* f_i(x^*)}_{\leq 0} + \sum_{j=1}^p \underbrace{\nu_j^* h_j(x^*)}_{=0} \\ &\leq f_0(x^*), \end{aligned} \tag{1}$$

其中

- 根据  $f_i(x^*) \leq 0$  和  $\lambda_i^* \geq 0, \forall i = 1, 2, \dots, m$ ，有  $\lambda_i^* f_i(x^*) \leq 0$ ；
- 根据  $h_j(x^*) = 0, \forall j = 1, 2, \dots, p$ ，有  $\nu_j^* h_j(x^*) = 0$ 。

显然，上述式中等式成立，即

$$f_0(x^*) = f_0(x^*) + \sum_{i=1}^m \lambda_i^* f_i(x^*) + \sum_{j=1}^p \nu_j^* h_j(x^*).$$

于是，可以得到如下重要结论：

$$\sum_{i=1}^m \lambda_i^* f_i(x^*) = 0.$$

由原对偶可行性可知，**求和项每项都非正**，因此

$$\begin{aligned} \lambda_i^* f_i(x^*) &= 0, \quad \forall i = 1, \dots, m, \\ \implies \begin{cases} \lambda_i^* > 0, & \implies f_i(x^*) = 0, \\ f_i(x^*) < 0, & \implies \lambda_i^* = 0. \end{cases} \end{aligned}$$

上述性质称为**互补松弛条件 (complementary slackness)**。

该条件表明：在最优点处，如果第  $i$  个约束没起作用（即  $f_i(x^*) < 0$ ），则相应的最优 Lagrange 乘子  $\lambda_i^* = 0$ 。

进一步，由式(1)可知：

$$\begin{aligned}\inf_x L(x, \lambda^*, \nu^*) &= \inf_x \left\{ f_0(x) + \sum_{i=1}^m \lambda_i^* f_i(x) + \sum_{j=1}^p \nu_j^* h_j(x) \right\} \\ &= f_0(x^*) + \sum_{i=1}^m \lambda_i^* f_i(x^*) + \sum_{j=1}^p \nu_j^* h_j(x^*) = L(x^*, \lambda^*, \nu^*).\end{aligned}$$

上式表明  $L(x, \lambda^*, \nu^*)$  关于  $x$  在  $x^*$  处取得极小值。根据无约束优化问题的最优性条件可知：(非凸时仅为必要条件)

$$\begin{aligned}\left. \frac{\partial L(x, \lambda^*, \nu^*)}{\partial x} \right|_{x=x^*} &= 0, \\ \Rightarrow \nabla f_0(x^*) + \sum_{i=1}^m \lambda_i^* \nabla f_i(x^*) + \sum_{j=1}^p \nu_j^* \nabla h_j(x^*) &= 0.\end{aligned}$$

上述等式称为**稳定性条件 (stationarity)**。

## KKT 条件（最优解的必要条件）

对于可微且对偶间隙为 0 的优化问题，原对偶最优解  $(x^*, \lambda^*, \nu^*)$  必须满足条件：

$$f_i(x^*) \leq 0, \quad i = 1, \dots, m, \quad (\text{primal feasibility})$$

$$h_j(x^*) = 0, \quad j = 1, \dots, p, \quad (\text{primal feasibility})$$

$$\lambda_i^* \geq 0, \quad i = 1, \dots, m, \quad (\text{dual feasibility})$$

$$\lambda_i^* f_i(x^*) = 0, \quad i = 1, \dots, m, \quad (\text{complementary slackness})$$

$$\nabla f_0(x^*) + \sum_{i=1}^m \lambda_i^* \nabla f_i(x^*) + \sum_{j=1}^p \nu_j^* \nabla h_j(x^*) = 0, \quad (\text{stationarity})$$

以上条件合称为 **Karush-Kuhn-Tucker (KKT)** 条件。

**思考：**KKT 条件一般只是必要条件，那么对于凸优化问题如何，即如果  $(\tilde{x}, \tilde{\lambda}, \tilde{\nu})$  满足 KKT 条件，是否能推导它是 (Primal) 和 (Dual) 的最优解？

## 定理 2 (KKT 条件是原对偶最优解的充要条件)

对于目标函数和约束函数均可微，且强对偶性成立的凸优化问题，有：

$$(\tilde{x}, \tilde{\lambda}, \tilde{\nu}) \text{ 为原对偶最优解} \iff (\tilde{x}, \tilde{\lambda}, \tilde{\nu}) \text{ 满足 KKT 条件.}$$

证明：

- 对于“ $\Rightarrow$ ”（必要性），我们已经证明了最优解必满足KKT条件；
- 对于“ $\Leftarrow$ ”（充分性），由  $\tilde{x}$  和  $(\tilde{\lambda}, \tilde{\nu})$  可行，只需证明  $g(\tilde{\lambda}, \tilde{\nu}) = f_0(\tilde{x})$ ，即可进一步推出  $\tilde{x}$  和  $(\tilde{\lambda}, \tilde{\nu})$  分别是(Primal)和(Dual)的最优解。具体分析如下：

1. 由于目标函数和约束函数均是可微凸函数，因此  $L(x, \tilde{\lambda}, \tilde{\nu})$  是关于  $x$  的可微凸函数。于是，可知

$$\underbrace{\left. \frac{\partial L(x, \tilde{\lambda}, \tilde{\nu})}{\partial x} \right|_{x=\tilde{x}}}_{\text{stationarity}} = 0 \quad \Rightarrow \quad \tilde{x} = \arg \min_x L(x, \tilde{\lambda}, \tilde{\nu})$$

2. 根据 Lagrange 对偶函数的定义:

$$\begin{aligned}
 g(\tilde{\lambda}, \tilde{\nu}) &= \inf_x L(x, \tilde{\lambda}, \tilde{\nu}) = L(\tilde{x}, \tilde{\lambda}, \tilde{\nu}) \\
 &= f_0(\tilde{x}) + \underbrace{\sum_{i=1}^m \tilde{\lambda}_i f_i(\tilde{x})}_{=0, \text{ 由互补松弛}} + \underbrace{\sum_{j=1}^p \tilde{\nu}_j h_j(\tilde{x})}_{=0, \text{ 由原问题可行性}} = f_0(\tilde{x})
 \end{aligned}$$

3. 根据弱对偶定理, 有  $d^* \leq p^*$ 。另一方面, 根据原对偶最优解的定义, 有

$$d^* = \sup_{\lambda \geq 0, \nu} g(\lambda, \nu) \geq g(\tilde{\lambda}, \tilde{\nu}) = f_0(\tilde{x}) \geq p^*.$$

故上式中等式成立, 于是

$$\begin{aligned}
 d^* &= \sup_{\lambda \geq 0, \nu} g(\lambda, \nu) = g(\tilde{\lambda}, \tilde{\nu}), \\
 p^* &= f_0(\tilde{x}).
 \end{aligned}$$

因此,  $(\tilde{x}, \tilde{\lambda}, \tilde{\nu})$  为原对偶最优解, 证毕。

## 总结:

- 对于一般的可微凸优化问题，如果强对偶性成立，则 KKT 条件为原对偶最优解需要满足的充要条件
- 对于一般的可微（非凸）优化问题，如果强对偶成立，则 KKT 条件为原对偶最优解需要满足的必要条件
- 绝大部分优化算法都是在寻找满足 KKT 条件及其推广条件的点

KKT (Karush-Kuhn-Tucker) 条件的相关历史（非正式叙述）:

- Lagrange 最早研究了带有等式约束的优化问题的最优性条件
- Kuhn 和 Turker 在1951年给出了带有不等式约束的优化问题的最优性条件
- 之后，人们发现 Karush 早在他1939年未发表的硕士论文中已提出了同样的最优性条件



# 例：一阶可微凸优化问题

考虑非负约束的可微凸优化问题：

$$\min_x f_0(x), \quad \text{s.t.} \quad x \geq 0.$$

写出它的 KKT 条件：

$$\left\{ \begin{array}{l} x^* \geq 0, \\ \lambda^* \geq 0, \\ \lambda_i^*(-x_i^*) = 0, \quad i = 1, \dots, n, \\ \nabla f_0(x^*) + (-\lambda^*) = 0. \end{array} \right. \iff \left\{ \begin{array}{l} x^* \geq 0, \\ \nabla f_0(x^*) \geq 0, \\ x_i^* [\nabla f_0(x^*)]_i = 0, \quad i = 1, \dots, n. \end{array} \right.$$

显然，对于该问题，Slater's condition 成立，因此强对偶性成立，进而满足 KKT 条件的点即为问题的最优解。

请同学们同时回顾第一章课件p91例2.





# 例：注水算法

## 注水(water filling)算法与问题背景

将总和为1的总功率的信号分配到  $n$  个信道传输，以获得**最大通信速率**：

$$\begin{aligned}
\min_x \quad & - \sum_{i=1}^n \log(\alpha_i + x_i) \quad \Leftarrow \text{等价于最小化负通信率} \\
\text{s.t.} \quad & x \geq 0 \quad \Leftarrow \text{功率非负} \\
& \mathbf{1}^\top x = 1 \quad \Leftarrow \text{功率总和为1}
\end{aligned}$$

其中  $\alpha_i > 0$  是已知的量，它代表第  $i$  个信道的状况。

该问题的 KKT 条件为

$$\begin{aligned}
x^* &\geq 0 \\
\mathbf{1}^\top x^* &= 1 \\
\lambda^* &\geq 0 \\
\lambda_i^* x_i^* &= 0, \quad i = 1, \dots, n \\
-\frac{1}{\alpha_i + x_i^*} - \lambda_i^* + \nu^* &= 0, \quad i = 1, \dots, n
\end{aligned}$$



## 例：注水算法（续）

根据  $-\frac{1}{\alpha_i + x_i^*} - \lambda_i^* + \nu^* = 0$ ,  $\lambda_i^* \geq 0$  和  $\lambda_i^* x_i^* = 0$  有:

$$\nu^* \geq \frac{1}{\alpha_i + x_i^*}, \quad x_i^* \left( \nu^* - \frac{1}{\alpha_i + x_i^*} \right) = 0, \quad i = 1, \dots, n$$

1. 若  $\nu^* < \frac{1}{\alpha_i}$ , 根据  $\nu^* \geq \frac{1}{\alpha_i + x_i^*}$ , 可得  $\frac{1}{\alpha_i} > \nu^* \geq \frac{1}{\alpha_i + x_i^*} \Rightarrow x_i^* > 0$ ;


于是, 由互补条件可知  $\lambda_i^* = 0$ , 此时  $x_i^* = \frac{1}{\nu^*} - \alpha_i$ ;

2. 若  $\nu^* > \frac{1}{\alpha_i}$ , 则由  $x_i^* \geq 0$  可知  $\nu^* > \frac{1}{\alpha_i + x_i^*}$ 。再由  $x_i^* (\nu^* - 1/(\alpha_i + x_i^*)) = 0$ , 可知  $x_i^* = 0$ ;

3. 若  $\nu^* = \frac{1}{\alpha_i}$ , 也可根据  $x_i^* (\nu^* - 1/(\alpha_i + x_i^*)) = 0$  推出  $x_i^* = 0$ 。

# 例：注水算法（续）

综上， $x_i^* = \max \left\{ 0, \frac{1}{\nu^*} - \alpha_i \right\}$ ，其中  $\nu^*$  满足  $\sum_{i=1}^n \max \left\{ 0, \frac{1}{\nu^*} - \alpha_i \right\} = 1$ ;



**Fig.** 求解该问题 KKT 点的算法有个很“形象”的名称：[注水算法](#)。假设我们有一口底部不平  
整的缸， $\alpha_i$  是缸底第  $i$  片区域的高度。逐渐向缸中注水，记水位为  $\frac{1}{\nu}$ 。不断注水直至总水量为  
1。此时，第  $i$  个区域对应的水位深度即为  $x_i^*$ !

§ Lagrange 对偶

§ Lagrange 对偶问题

§ Lagrange 对偶的几种解释

§ 最优性条件

§ 敏感性分析

在本节，我们希望研究约束条件的变化会如何影响原问题的最优值。

## 考虑一般优化问题

$$\begin{array}{ll}\min & f_0(x) \\ \text{s.t.} & f_i(x) \leq 0, \quad i = 1, \dots, m, \\ & h_j(x) = 0, \quad j = 1, \dots, p.\end{array}$$

记该问题定义域  $\mathcal{D} = \bigcap_{i=1}^m \text{dom } f_i \cap \bigcap_{j=1}^p \text{dom } h_j$ .

考虑对该优化问题的约束施加扰动：

## 一般优化问题的扰动问题

$$\begin{array}{ll}\min & f_0(x) \\ \text{s.t.} & f_i(x) \leq u_i, \quad i = 1, \dots, m, \\ & h_j(x) = w_j, \quad j = 1, \dots, p.\end{array}$$

记扰动问题的最优值为  $p^*(u, w)$ 。原问题的最优值自然对应为  $p^*(0, 0)$

## 性质1

若原问题为凸优化问题, 则  $p^*(u, w)$  是关于  $(u, w)$  的凸函数。

证明: 回顾凸优化问题的定义:

$$\begin{array}{ll} \min_x & f_0(x) & f_0 : \text{凸函数;} \\ \text{s.t.} & f_i(x) \leq 0, \quad i = 1, \dots, m, & f_i : \text{凸函数;} \\ & h_j(x) = 0, \quad j = 1, \dots, p, & h_j(x) = a_j^\top x - b_j : \text{仿射函数.} \end{array}$$

根据带有扰动的一般优化问题的定义, 将  $p^*(u, w)$  记为

$$p^*(u, w) = \begin{cases} \inf_{x \in \mathcal{D}} \left\{ f_0(x) \mid \begin{array}{l} f_i(x) \leq u_i, \quad i = 1, \dots, m \\ h_j(x) = w_j, \quad j = 1, \dots, p \end{array} \right\}, & \text{如果问题可行;} \\ +\infty, & \text{如果问题不可行.} \end{cases}$$

对于函数  $p^*(u, w)$ , 易知它的定义域  $\text{dom } p^* = \mathbb{R}^m \times \mathbb{R}^p$  为凸集。

考虑任意两组  $(u^{(1)}, w^{(1)}), (u^{(2)}, w^{(2)}) \in \text{dom } p^*$ , 其对应扰动问题的可行域, 分别记为

$$\mathcal{X}_1^* = \left\{ x \in \mathcal{D} \left| \begin{array}{ll} f_i(x) \leq u_i^{(1)}, & i = 1, \dots, m \\ h_j(x) = w_j^{(1)}, & j = 1, \dots, p \end{array} \right. \right\}$$

和

$$\mathcal{X}_2^* = \left\{ x \in \mathcal{D} \left| \begin{array}{ll} f_i(x) \leq u_i^{(2)}, & i = 1, \dots, m \\ h_j(x) = w_j^{(2)}, & j = 1, \dots, p \end{array} \right. \right\}$$

1. 如果  $\mathcal{X}_1^* = \emptyset$  或  $\mathcal{X}_2^* = \emptyset$ , 则  $p^*(u^{(1)}, w^{(1)}) = +\infty$  或  $p^*(u^{(2)}, w^{(2)}) = +\infty$ 。

因此, 对  $\forall \theta \in [0, 1]$  有

$$\begin{aligned} & \theta p^*(u^{(1)}, w^{(1)}) + (1 - \theta) p^*(u^{(2)}, w^{(2)}) \\ & \geq p^*(\theta u^{(1)} + (1 - \theta) u^{(2)}, \theta w^{(1)} + (1 - \theta) w^{(2)}) \end{aligned}$$



# 敏感性分析（续）

2. 如果  $\mathcal{X}_1^* \neq \emptyset$  且  $\mathcal{X}_2^* \neq \emptyset$ , 则根据凸优化问题的性质, 对  $\forall x_1 \in \mathcal{X}_1^*$ ,  $\forall x_2 \in \mathcal{X}_2^*$  和  $\forall \theta \in [0, 1]$ , 有以下结论:

- $\theta x_1 + (1 - \theta)x_2 \in \mathcal{D}$ ; (根据  $x_1, x_2 \in \mathcal{D}$  且  $\mathcal{D}$  为凸集)
- $f_i(\theta x_1 + (1 - \theta)x_2) \leq \theta f_i(x_1) + (1 - \theta)f_i(x_2) \leq \theta u_i^{(1)} + (1 - \theta)u_i^{(2)}$ ;  
(根据  $f_i, i = 1, \dots, m$ , 为凸函数)
- $h_j(\theta x_1 + (1 - \theta)x_2) = \theta h_j(x_1) + (1 - \theta)h_j(x_2) = \theta w_j^{(1)} + (1 - \theta)w_j^{(2)}$ ;  
(根据  $h_j, j = 1, \dots, p$ , 为仿射函数)

上述结论表明: 凸组合  $\theta x_1 + (1 - \theta)x_2$  是扰动问题

$$\begin{aligned} \min \quad & f_0(x) \\ \text{s.t.} \quad & f_i(x) \leq \theta u_i^{(1)} + (1 - \theta)u_i^{(2)}, \quad i = 1, \dots, m, \\ & h_j(x) = \theta w_j^{(1)} + (1 - \theta)w_j^{(2)}, \quad j = 1, \dots, p, \end{aligned}$$

的一个可行解, 因此对  $\forall x_1 \in \mathcal{X}_1^*, \forall x_2 \in \mathcal{X}_2^*$  和  $\forall \theta \in [0, 1]$  必有

$$f_0(\theta x_1 + (1 - \theta)x_2) \geq p^*(\theta u^{(1)} + (1 - \theta)u^{(2)}, \theta w^{(1)} + (1 - \theta)w^{(2)})$$



3. 进一步, 根据目标函数  $f_0$  的凸性和上述不等式, 有

$$\begin{aligned}\theta f_0(x_1) + (1 - \theta)f_0(x_2) &\geq f_0(\theta x_1 + (1 - \theta)x_2) \\ &\geq p^*(\theta u^{(1)} + (1 - \theta)u^{(2)}, \theta w^{(1)} + (1 - \theta)w^{(2)}).\end{aligned}$$

于是, 取不等式左侧  $\theta f_0(x_1) + (1 - \theta)f_0(x_2)$  的下确界, 有

$$\begin{aligned}&\inf_{x_1 \in \mathcal{X}_1^*, x_2 \in \mathcal{X}_2^*} \{\theta f_0(x_1) + (1 - \theta)f_0(x_2)\} \\ &= \inf_{x_1 \in \mathcal{X}_1^*} \theta f_0(x_1) + \inf_{x_2 \in \mathcal{X}_2^*} (1 - \theta)f_0(x_2) \quad (\text{根据变量 } x_1, x_2 \text{ 的可分性}) \\ &= \theta p^*(u^{(1)}, w^{(1)}) + (1 - \theta)p^*(u^{(2)}, w^{(2)}).\end{aligned}$$

结合上述两式可得

$$\theta p^*(u^{(1)}, w^{(1)}) + (1 - \theta)p^*(u^{(2)}, w^{(2)}) \geq p^*(\theta u^{(1)} + (1 - \theta)u^{(2)}, \theta w^{(1)} + (1 - \theta)w^{(2)}).$$

函数  $p^*(u, w)$  的凸性由此得证!



# 敏感性分析 (续)

## 性质2

若原问题为凸问题，对偶间隙为0，设  $(\lambda^*, \nu^*)$  为原问题对偶最优解，则

$$p^*(u, w) \geq p^*(0, 0) - (\lambda^*)^\top u - (\nu^*)^\top w.$$

证明：设  $\tilde{x}$  为扰动问题的任意可行解，即

$$\tilde{x} \in \mathcal{X} = \left\{ x \in \mathcal{D} \left| \begin{array}{ll} f_i(\tilde{x}) \leq u_i & i = 1, \dots, m \\ h_j(\tilde{x}) = w_j & j = 1, \dots, p \end{array} \right. \right\}$$

进一步，根据对偶间隙为0，有

$$\begin{aligned}
p^*(0, 0) &= g(\lambda^*, \nu^*) \\
&\leq f_0(\tilde{x}) + \sum_{i=1}^m \lambda_i^* f_i(\tilde{x}) + \sum_{j=1}^p \nu_j^* h_j(\tilde{x}) && \text{根据 } g(\lambda^*, \nu^*) = \inf_x L(x, \lambda^*, \nu^*) \\
&\leq f_0(\tilde{x}) + (\lambda^*)^\top u + (\nu^*)^\top w && \text{根据 } f_i(\tilde{x}) \leq u_i, h_j(\tilde{x}) = w_j \\
\Rightarrow f_0(\tilde{x}) &\geq p^*(0, 0) - (\lambda^*)^\top u - (\nu^*)^\top w \\
\Rightarrow p^*(u, w) &\geq p^*(0, 0) - (\lambda^*)^\top u - (\nu^*)^\top w. && \text{根据 } p^*(u, w) = \inf_{x \in \mathcal{X}} f_0(x)
\end{aligned}$$

至此性质2得证。



# 敏感性分析 (续)

根据性质2可以观察到:

- 若  $\lambda_i^*$  很大, 如果加强不等式约束为  $f_i(x) \leq u_i < 0$ , 则最优值增大。
- 若  $\nu_i^*$  为较大的正值, 如果  $w_i < 0$ , 则最优值增大。
- 若  $\nu_i^*$  为较小的负值, 如果  $w_i > 0$ , 则最优值增大。

## 性质3 (局部敏感性)

若原问题为凸, 对偶间隙为0且  $p^*(u, w)$  在  $(u, w) = (0, 0)$  点处可微, 则原始问题的最优对偶变量  $(\lambda^*, \nu^*)$  满足

$$\lambda_i^* = -\nabla_{u_i} p^*(0, 0) \quad \nu_i^* = -\nabla_{w_i} p^*(0, 0).$$

性质3表明, 在局部区域有

$$p^*(u, w) \approx p^*(0, 0) + \nabla^\top p^*(0, 0) \begin{bmatrix} u \\ w \end{bmatrix} = p^*(0, 0) - (\lambda^*)^\top u - (\nu^*)^\top w.$$

## 0-1 整数线性规划问题（非凸）

$$\begin{aligned} \min \quad & c^\top x \\ \text{s.t.} \quad & Ax \leq b, \\ & x_i \in \{0, 1\}, \quad i = 1, \dots, n, \end{aligned}$$

其中决策变量  $x$  的每一个分量  $x_i$  只能取值 0 或 1。

**思路1：**一种容易想到的思路是对约束  $x_i \in \{0, 1\}$  进行松弛。

## 0-1 整数线性规划的松弛问题

$$\begin{aligned} \min \quad & c^\top x \\ \text{s.t.} \quad & Ax \leq b, \\ & 0 \leq x_i \leq 1, \quad i = 1, \dots, n. \end{aligned}$$

- 松弛过后的问题成为线性规划问题（凸）；
- 显然，松弛问题的最优值比原来要更小，但最优解不一定取值为 0 或 1。

思路2: 为了避免改变可行域, 我们考虑等价地改写约束  $x_i \in \{0, 1\}$ 。

## 0-1 整数线性规划的等价问题

$$\begin{aligned} \min \quad & c^\top x \\ \text{s.t.} \quad & Ax \leq b, \\ & x_i(x_i - 1) = 0, \quad i = 1, \dots, n. \end{aligned}$$

显然, 该等价问题的可行域和最优解都与原问题相同。

进一步, 写出等价问题的 Lagrange 函数

$$\begin{aligned} L(x, \lambda, \nu) &= c^\top x + \lambda^\top (Ax - b) + \sum_{i=1}^n \nu_i (x_i^2 - x_i) \\ &= \sum_{i=1}^n \nu_i x_i^2 + (c + \lambda^\top A - \nu^\top)^\top x - \lambda^\top b \end{aligned}$$



写出对偶函数:

$$\begin{aligned} g(\lambda, \nu) &= \inf_x L(x, \lambda, \nu) \\ &= \begin{cases} -\lambda^\top b - \frac{1}{4} \sum_{i=1}^n \frac{(c_i + a_i^\top \lambda - \nu_i)^2}{\nu_i}, & \nu_i \geq 0, \forall i = 1, 2, \dots, n, \\ -\infty, & \text{otherwise,} \end{cases} \end{aligned}$$

其中  $a_i$  为矩阵  $A$  的第  $i$  列。

写出对偶问题:

$$\begin{aligned} \max \quad & -\lambda^\top b - \frac{1}{4} \sum_{i=1}^n \frac{(c_i + a_i^\top \lambda - \nu_i)^2}{\nu_i} \\ \text{s.t.} \quad & \lambda \geq 0, \quad \nu \geq 0. \end{aligned}$$

# 利用对偶理解“启发式”方法



进一步, 可以利用  $\max_{\lambda, \nu} g(\lambda, \nu) = \max_{\lambda} \max_{\nu} g(\lambda, \nu)$  消去  $\nu$ 。

事实上, 对任意  $\lambda$ , 考虑关于  $\nu$  的优化问题:

$$\begin{aligned} & \max_{\nu \geq 0} \quad -\lambda^\top b - \frac{1}{4} \sum_{i=1}^n \frac{(c_i + a_i^\top \lambda - \nu_i)^2}{\nu_i} \\ \Leftrightarrow & \quad -\lambda^\top b + \sum_{i=1}^n \max_{\nu_i \geq 0} \left\{ -\frac{1}{4} \frac{(c_i + a_i^\top \lambda - \nu_i)^2}{\nu_i} \right\} \end{aligned}$$

对于  $z_i^* := \max_{\nu_i \geq 0} \left\{ -\frac{1}{4} \frac{(c_i + a_i^\top \lambda - \nu_i)^2}{\nu_i} \right\}$ , 可通过分情况讨论:

$$\begin{aligned} z_i^* &:= \begin{cases} c_i + a_i^\top \lambda, & c_i + a_i^\top \lambda \leq 0, & (\nu_i^{*, \lambda} = -(c_i + a_i^\top \lambda)) \\ 0, & c_i + a_i^\top \lambda > 0, & (\nu_i^{*, \lambda} = c_i + a_i^\top \lambda) \end{cases} \\ &= \min \{0, c_i + a_i^\top \lambda\}. \end{aligned}$$



于是，可以将对偶问题等价地改写为

$$\max_{\lambda} \quad -\lambda^{\top} b + \sum_{i=1}^n \min \{0, c_i + a_i^{\top} \lambda\}, \quad \text{s.t.} \quad \lambda \geq 0.$$

引入新变量  $\omega$ ，上述问题可进一步等价于

$$\begin{aligned} \max_{\lambda, \omega} \quad & -\lambda^{\top} b + \mathbf{1}^{\top} \omega \\ \text{s.t.} \quad & \lambda \geq 0, \quad \omega \leq 0, \\ & \omega_i \leq a_i^{\top} \lambda + c_i, \quad i = 1, \dots, n, \end{aligned}$$

其中  $\mathbf{1}$  为元素都为 1 的向量。



# 利用对偶理解“启发式”方法



回顾 0-1 整数线性规划的松弛问题:

$$\begin{aligned} \min \quad & c^\top x \\ \text{s.t.} \quad & Ax \leq b \\ & 0 \leq x_i \leq 1, \quad i = 1, \dots, n. \end{aligned}$$

它的拉格朗日函数为

$$\begin{aligned} L(x, u, v, t) &= c^\top x + u^\top (Ax - b) - v^\top x + t^\top (x - \mathbf{1}) \\ &= (c + A^\top u - v + t)^\top x - b^\top u - \mathbf{1}^\top t. \end{aligned}$$

对偶函数为

$$g(u, v, t) = \begin{cases} -b^\top u - \mathbf{1}^\top t, & c + A^\top u - v + t = 0, \\ -\infty, & \text{otherwise.} \end{cases}$$

对偶问题为

$$\begin{aligned} \max_{u, v, t} \quad & -b^\top u - \mathbf{1}^\top t \\ \text{s.t.} \quad & c + A^\top u - v + t = 0 \\ & u \geq 0, \quad v \geq 0, \quad t \geq 0. \end{aligned} \quad \Leftrightarrow \quad \begin{aligned} \max_{u, t} \quad & -b^\top u - \mathbf{1}^\top t \\ \text{s.t.} \quad & c + A^\top u + t \geq 0 \\ & u \geq 0, \quad t \geq 0. \end{aligned}$$

# 利用对偶理解“启发式”方法

对比“松弛问题”的对偶和“等价问题”的对偶：

$$\begin{array}{ll}
 \max_{u, t} & -b^\top u - \mathbf{1}^\top t \\
 \text{s.t.} & c + A^\top u + t \geq 0 \\
 & u \geq 0, \quad t \geq 0.
 \end{array}
 \iff
 \begin{array}{ll}
 \max_{\lambda, \omega} & -\lambda^\top b + \mathbf{1}^\top \omega \\
 \text{s.t.} & \lambda \geq 0, \quad \omega \leq 0, \\
 & \omega_i \leq a_i^\top \lambda + c_i \quad i = 1, \dots, n.
 \end{array}$$

